

1. Mecanismo do Viés

O viés no modelo ocorre devido à seleção restrita e não rotulada corretamente dos dados de treinamento. No dataset utilizado, foram incluídas imagens de pessoas com astigmatismo e miopia, porém sem identificação explícita de qual condição cada indivíduo possuía. Dessa forma, o algoritmo não recebeu informações suficientes para aprender padrões reais entre as classes.

Como resultado, o modelo passou a associar características aleatórias das imagens — como iluminação, posição do rosto, formato do óculos ou características faciais — em vez de aprender diferenças relacionadas às condições visuais. Isso compromete a lógica de aprendizado do algoritmo, pois ele constrói padrões com base em correlações acidentais e não em relações reais.

Além disso, o desequilíbrio no resultado final (13% astigmatismo e 87% miopia) indica que o modelo internalizou uma distribuição distorcida, produzindo uma visão incorreta da realidade. Esse tipo de viés ocorre frequentemente quando os dados são incompletos, mal rotulados ou desbalanceados, levando o sistema a gerar previsões que não refletem corretamente o mundo real.

2. Consequência Social

Quando sistemas de inteligência artificial apresentam viés, as consequências podem afetar diretamente as pessoas que dependem dessas classificações. No caso de um sistema que identifica condições visuais, um indivíduo com astigmatismo pode ser classificado incorretamente como tendo miopia, ou vice-versa.

Esse erro pode gerar frustração emocional e perda de confiança na tecnologia, especialmente se o sistema for utilizado em contextos relacionados à saúde, educação ou serviços digitais. Além disso, classificações incorretas podem levar a recomendações inadequadas ou à invisibilização de certos grupos, prejudicando a representação correta dessas condições.

Do ponto de vista profissional ou médico, um sistema enviesado pode contribuir para decisões equivocadas, como indicar tratamentos ou diagnósticos incorretos. Isso reforça a importância de desenvolver sistemas de IA com dados representativos e devidamente validados, garantindo que diferentes grupos sejam tratados de forma justa e precisa.

3. Ação Mitigadora (Human-in-the-loop)

Uma abordagem eficaz para reduzir esse tipo de viés é implementar um processo de Human-in-the-loop (HITL) durante a curadoria e validação dos dados.

Nesse processo, especialistas ou revisores humanos participam ativamente da construção do dataset antes do treinamento do modelo. Eles podem:

- Revisar e rotular corretamente os dados, identificando quais imagens pertencem a cada classe.
- Garantir equilíbrio entre as categorias (por exemplo, número semelhante de exemplos de astigmatismo e miopia).
- Identificar possíveis inconsistências ou padrões incorretos que o algoritmo poderia aprender.
- Realizar uma validação manual do conjunto de dados antes da etapa de treinamento.

Essa intervenção humana permite detectar e corrigir problemas de qualidade ou representatividade nos dados, garantindo que o modelo aprenda padrões mais confiáveis e reduzindo o risco de reproduzir vieses durante a aplicação prática do sistema.